

# Deteksi dan Visualisasi Berbasis *Computer Vision* untuk Analisis Gambar Dermatologis dalam Penilaian Keparahan Jerawat

Lulu'ul Watef<sup>1</sup>, Faizal Mahanto<sup>2,\*</sup>

Departemen Sistem Informasi, Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember, Indonesia

<sup>1</sup>6026202007student.its.ac.id; <sup>2</sup>faizal@is.its.ac.id

\* penulis korespondensi

## INFO ARTIKEL

### Sejarah Artikel

Diterima: 31 Januari 2024  
Direvisi: 12 Februari 2024  
Diterbitkan: 30 April 2024

### Kata Kunci

*Acne Vulgaris*  
*Classification*  
*Enhanced Image*  
*Image Preprocessing*  
*Threshold*

## ABSTRAK

Jerawat (*acne vulgaris*) merupakan salah satu penyakit dermatologis paling umum dalam kehidupan sehari-hari utamanya pada masa remaja. Lebih dari 80% orang mengalami permasalahan jerawat pada masa remajanya. Dalam menilai tingkat keparahan jerawat perlu dilakukan penilaian secara obyektif dengan prosedur perawatan medis. Penilaian jerawat secara tradisional umumnya dilakukan oleh dokter kulit dengan menentukan jenis dan jumlah lesi dimana sering kali penilaian ini memakan waktu dan mengganggu efisiensi dalam penilaian jerawat. Kerangka kerja ini menguji praproses gambar dengan menggunakan metode *red color detection*, *threshold*, *enhanced image* dan penggabungan *enhanced image* dan *red color detection* dalam klasifikasi gambar jerawat. Selain itu beberapa metode klasifikasi diterapkan untuk menguji data masukan dari penerapan praproses yang dilakukan. Adapun metode klasifikasi yang digunakan adalah NN, SVM, KNN dan VGG16 selain itu penerapan fitur ekstraksi juga diterapkan. Penggunaan fitur ekstraksi menggunakan VGG16 dilanjutkan dengan Principal Component Analysis (PCA) dimana penerapan PCA dilakukan untuk meningkatkan efisiensi komputasional. Dengan data masukan *enhanced image* yang kemudian diklasifikasikan menggunakan VGG16 memberikan hasil akurasi terbaik mencapai 69% . Kedepannya metode praproses *enhanced image* dapat diterapkan pada kumpulan data yang berbeda dikarenakan tidak dipungkiri bahwasanya kumpulan data ACNE04 memiliki banyak *noise* pada citra.

## PENDAHULUAN

Jerawat (*acne vulgaris*) merupakan salah satu penyakit dermatologi paling umum pada kehidupan sehari-hari yang menyerang orang-orang dari segala usia terutama di masa remaja [1]. Lebih dari 80% orang mengalami permasalahan jerawat pada masa remajanya [2]. Jerawat sendiri merupakan suatu penyakit multifaktorial yang umumnya disebabkan oleh kadar androgen yang tidak normal, sekresi sebum yang berlebihan, keratosis abnormal di sekitar folikel rambut dan juga peradangan. Selain itu faktor seperti genetik, stres psikologis, pola makan dan imunitas juga mempengaruhi munculnya jerawat dan keparahan kondisi jerawat [3]. Jerawat memiliki pengaruh pada kelenjar sebacea pada kulit utamanya pada wajah, leher, dada, punggung dan lengan atas [1]. Jerawat memiliki tingkat keparahan bervariasi [4] dan merupakan salah satu penyakit dengan kondisi yang tidak mengancam jiwa mengakibatkan jerawat sendiri diremehkan oleh profesional layanan kesehatan karena pada umumnya jerawat dapat sembuh sendiri [1].

Tingkat keparahan jerawat sendiri memiliki peranan penting dalam menentukan penyembuhannya [5]. Dalam suatu penelitian mengatakan bahwasanya pengobatan yang berkaitan dengan jerawat menjadi salah satu beban finansial [1]. Penilaian tingkat keparahan

menjadi penting sehingga deteksi tingkat keparahan jerawat sesuai lesi diperlukan untuk dapat dilakukan asesmen awal yang nantinya dapat membantu memberikan rekomendasi penanganan perawatan yang cocok sesuai dengan tingkat keparahan yang diderita [1] dimana pada kasus tertentu perawatan khusus tentunya diperlukan untuk pasien jerawat dikarenakan jerawat dapat menyebabkan hiperpigmentasi dan pembentukan bekas luka [3].

Dalam melakukan penilaian jerawat diperlukan penilaian yang objektif dan dapat diandalkan oleh dermatolog untuk membuat keputusan perawatan yang tepat dan sesuai dengan standar. Metode penilaian jerawat tradisional umumnya bersifat subjektif yang bergantung pada identifikasi jenis lesi, selain itu penilaian jerawat secara tradisional memakan waktu bagi dermatolog [1] dan sering kali mengganggu efisiensi dalam penilaian jerawat [6]. Hal ini mengakibatkan penilaian jerawat dilakukan secara kualitatif dalam menilai tingkat keparahan, bukan penghitungan lesi [7]. Pada penilaian tingkat keparahan jerawat, beberapa penelitian menggunakan metode konsensus Delphi dan survei diantara para ahli klinis [7].

Dengan perkembangan teknologi saat ini, *artificial intelligence* dapat membuka jalan untuk melakukan pemodelan dalam pendeteksi objek berbasis *computer vision* dalam hal ini mengenali kondisi dermatologi melalui data citra [2]. Deteksi objek sendiri merupakan tugas untuk melakukan identifikasi objek yang diberikan dengan melokalisasi objek menggunakan batasan tertentu dan melakukan klasifikasi objek dengan label [8]. Klasifikasi citra sendiri merupakan salah satu contoh dari penerapan *computer vision* [3] dimana klasifikasi citra dianggap sebagai salah satu permasalahan umum pada *computer vision* [4]. Selain itu penerapan *computer vision* sendiri memberikan penerapan yang baik dalam pembedahan dan terapi dalam suatu penyakit tertentu [5]. Studi sebelumnya yang berkaitan dengan penilaian keparahan jerawat dilakukan dengan melakukan penyaringan informasi dimana informasi yang tidak penting dibuang dengan proses melakukan deteksi wajah, lipatan informasi dan segmentasi area utamanya [9]. Dari proses tersebut kemudian diperkuat dengan kesenjangan warna yang ada pada area kulit dengan melakukan observasi secara global [9]. Metode lainnya dilakukan dengan menggunakan metode penyesuaian karakteristik dari jerawat dengan melakukan penyulingan pengetahuan. Terlepas dari kriteria jerawat, metode ini melakukan diagnosis berdasarkan kasus lesi yang mempertimbangkan jumlah dan jenis lesinya [5]. Pendekatan lainnya, mengembangkan metode pencitraan untuk penilaian jerawat otomatis dimana proses ekstraksinya melalui proses *adaptive thresholding* dan *filter Laplacian of gaussian* [10].


Penelitian sebelumnya berkaitan dengan penilaian tingkat keparahan jerawat pernah dilakukan dengan menggunakan Key Information Enhancement (KEI) yang memanfaatkan kekhususan gambar wajah untuk menyaring informasi yang tidak penting dan secara efisien meningkatkan informasi penting kemudian dilanjutkan dengan segmentasi, augmentasi kemudian menerapkan metode *Global Local Fusion Network* (GLFNet) untuk memperkuat persepsi kesenjangan warna antara kulit dan wajah secara keseluruhan dalam proses klasifikasi [9]. Penelitian lainnya menggunakan *Diagnostic Evidence Distillation*. Struktur destilasi pengetahuan guru-siswa dimana strategi ini menunjukkan area utama yang harus diamati oleh guru untuk mengenali pola berbagai jenis lesi yang merupakan salah satu aspek bukti diagnostik. Destilasi bukti diagnostik mengubah pengetahuan yang menyatu dengan bukti ke dalam model siswa dimana model siswa merupakan model diagnosis akhir [5].

Adapun model klasifikasi pada beberapa penelitian menguji coba beberapa model dengan *Convolutional Neural Network* (CNN) sebagai tulang punggung model diagnosis untuk meniru estimasi diagnosis global dari dermatolog [5] [9], CNN sendiri merupakan jaringan saraf tiruan yang khusus dirancang untuk aplikasi *computer vision* dengan menggabungkan citra visual [2], tak hanya itu metode berbasis CNN juga secara signifikan memajukan *computer vision* dalam hak analisis dan klasifikasi citra medis [4]. Sedangkan

dalam penelitian lainnya yaitu klasifikasi kanker darah [11]. Pada penelitian tersebut, mengekstrak fitur dari model CNN, dan kemudian memasukkan fitur yang diekstraksi ke pemilih fitur seperti *Principal Component Analysis* (PCA), *Linear Discriminant Analysis* (LDA), dan Pemilih Fitur SVC, bersama dengan dua algoritma *Particle Swarm Optimization* (PSO) dan *Cat Swarm Optimization* (CSO) dimana tujuh pengklasifikasi ML diuji coba dalam penelitian ini. Klasifikasi dengan menerapkan pemilihan fitur dan optimasi dapat meningkatkan nilai akurasi dibandingkan klasifikasi konvensional [11].

Dengan tujuan mendiagnosis tingkat keparahan jerawat menggunakan kumpulan data ACNE04 dilakukan praproses data citra dengan beberapa metode yang berbeda yang kemudian dilanjutkan dengan klasifikasi. Penelitian ini melakukan eksperimen dalam praproses data citra. Praproses dilakukan dengan menggunakan metode *enhanced image*, *threshold*, *red color detection* serta menggabungkan *enhanced image* dan *red color detection*. Selanjutnya untuk klasifikasi dilakukan dengan beberapa metode yaitu NN, SVM, KNN dan juga VGG16 yang merupakan salah satu arsitektur dari CNN. Kontribusi yang diberikan pada penelitian ini adalah mengetahui metode yang cocok dalam meningkatkan kualitas data citra jerawat pada studi kasus ini, dimana metode yang memberikan hasil akurasi terbaik adalah VGG16 dengan data masukan *enhanced image*.

## METODE



Gambar 1. Tahapan Penelitian

Tahapan penelitian ini digambarkan pada Gambar 1, dimana awal penelitian ini dimulai dari kumpulan data dermatologi jerawat yang kemudian dilakukan pengolahan data citra dengan berbagai praproses. Setelah kumpulan data jerawat dilakukan praproses, data tersebut dijadikan sebagai data masukan yang selanjutnya dilakukan klasifikasi. Dari klasifikasi yang dilakukan didapatkan nilai akurasi yang selanjutnya dijadikan bahan evaluasi.

## Data

Data dermatologi jerawat yang digunakan pada penelitian ini diambil dari kumpulan data ACNE04 [1] dengan gambaran level keparahan seperti yang ada pada gambar 2. Kumpulan ACNE04 merupakan kumpulan data yang tingkat pembagian keparahan jerawatnya dibagi menurut Hayashi dimana Hayashi hanya mempertimbangkan jumlah lesi untuk menentukan tingkat keparahan jerawat dan kumpulan data citra jerawat tersebut berisi hasil anotasi lokasi lesi, penghitungan lesi, dan tingkat keparahan semua gambar. Kumpulan data diambil dari wajah-wajah Asia yang berisi total 1457 gambar. Adapun sampel dari masing-masing level pada kumpulan data penderita jerawat dapat dilihat pada Gambar 2.



Gambar 2. Citra Jerawat dalam Berbagai Level

### Praproses Citra

Data citra digital (*digital image processing*) adalah ilmu yang mempelajari bagaimana gambar dibentuk, diolah dan dianalisis dengan luaran informasi yang dapat dipahami [6]. Data citra medis merupakan sebagian besar yang tercakup dalam *big medical data*. Klasifikasi citra medis sendiri, merupakan langkah mendasar dalam analisis citra medis yang bertujuan untuk membedakan citra medis berdasarkan kriteria tertentu [7]. Fitur warna dalam praproses data citra memiliki peranan penting. empat tipe dasar gambar/citra dipertimbangkan menurut warna dan skala abu-abu gambar[8]:

#### a. Binary image

Merupakan citra digital yang paling sederhana karena pikselnya hanya mengandung warna hitam atau putih[18]. Citra biner merupakan citra yang pikselnya hanya sebesar 1 bit sehingga nilai intensitas pada gambar hanya 0 (hitam) dan 1 (putih) [19].

#### b. Grayscale

Gambar 8 bit yang terdiri dari derajat hitam dan putih yang dibagi ke dalam 256 derajat [19]. Setiap pikselnya memiliki tingkat keabuan dari 0-255 dengan 0 berarti hitam dan 255 adalah putih [18].

#### c. Indexed color image

Gambar dengan warna yang hanya sebagian kecil warna yang digunakan misalnya 256 warna atau kurang, gambar dapat diwakili oleh palet warna untuk kemudahan dalam penyimpanan dan penanganan berkas.

#### d. True color image

Model warna terdiri dari RGB, HIS, HSV dan lainnya. Dalam model *red, green and blue*, setiap piksel dalam gambar diwakili oleh jumlah R, G, dan B yang dikandungnya. Masing-masing kanal warna tersebut memiliki intensitas sebesar 8 bit yang berarti memiliki rentang 0-255 [19]. Sedangkan *Hue*, *saturation*, dan *lighting* dapat digunakan untuk menggambarkan ruang warna yang dilihat oleh mata manusia. Model penglihatan warna yang telah dikembangkan diantaranya adalah HSV (*hue, saturation, value*), HIS (*hue, lighting saturation*), HLS (*hue, lightness, saturation*) dan HVC (*hue, value, chrome*) [18].

Adapun praproses gambar yang akan dilakukan yaitu:

#### a. Thresholding

Segmentasi gambar medis yang akurat merupakan langkah kunci dalam penggunaan kecerdasan buatan [9]. Pendekatan umum dalam segmentasi gambar dibagi menjadi empat tipe yaitu *thresholding*, berbasis wilayah, berbasis diagram dan berbasis pengelompokan [10]. *Thresholding* merupakan salah satu proses pada segmentasi data citra. Dengan membagi piksel gambar ke dalam kategori berbeda dalam rentang lokal tertentu dengan menetapkan ambang batas fitur tertentu untuk setiap piksel gambar [11] yang berarti proses *thresholding* sendiri digunakan untuk memisahkan objek yang diinginkan (*foreground*) dan objek yang tidak diinginkan (*background*). Objek yang dikehendaki dengan segmentasi ini akan dipresentasikan dengan warna putih dan sebaliknya untuk objek yang tidak dikehendaki. Dalam melakukan segmentasi pada suatu citra dapat dilakukan dengan metode *trial and error* namun dengan jumlah kasus yang banyak dibutuhkan metode untuk menentukan *threshold* secara otomatis [6]. Segmentasi dengan menggunakan *thresholding* menjadi

penting pada beberapa tahun terakhir karena kesederhanaan dan ketahanannya [12]. Keunggulan lainnya dari teknik *thresholding* adalah kecepatan pemrosesan yang baik dan penggunaan penyimpanan yang lebih sedikit [10]. Pada tahap praproses *thresholding* tentunya yang dilakukan pertama adalah dengan menentukan nilai ambang terlebih dahulu yang selanjutnya data citra diubah menjadi citra yang memiliki fitur warna biner. Adapun nilai ambang yang ditetapkan pada metode ini yaitu 128.

*b. Image Enhancement (Peningkatan Gambar)*

*Image enhancement* diterapkan guna perbaikan global maupun lokal untuk menghasilkan gambar dengan detail yang jelas dan kualitas lebih tinggi [13]. Adapun istilah lainnya yang digunakan khususnya pada wajah adalah *Key Information Enhancement* menurut Lin et al yang merupakan metode praproses yang adaptif, dengan memanfaatkan kekhususan gambar objek untuk menyaring bagian yang tidak penting dan meningkatkan informasi area utama. Dengan adanya latar belakang pada objek maka deteksi objek dilakukan sehingga area-area yang tidak berarti dihilangkan dimana kumpulan data tersisa adalah daya dengan anotasi lokasi objek. Selanjutnya data yang dianggap bukan area objek akan dihitamkan dan area objek akan menjadi area informasi [1].

Pada praproses ini dilakukan peningkatan kualitas citra diawali dengan mengurangi *noise* pada gambar menggunakan *Gaussian Blur* yang selanjutnya dilakukan penyesuaian histogram pada citra. Peningkatan kontras dan kecerahan juga dilakukan dengan pengaturan nilai *alpha* untuk meningkatkan kontras adalah 1.5 dengan nilai beta adalah 30 untuk meningkatkan kecerahan. Kemudian dilanjutkan dengan mempertajam citra dengan menekankan intensitas piksel dimana piksel yang ada disekitarnya dilemahkan.

*c. Red Color Detection*

Warna kulit bergantung pada beberapa faktor biologis dan lingkungan termasuk genetika, paparan sinar UV, dan keberadaan kromofor lain di kulit [14]. Jerawat dengan peradangan dominan berwarna merah [15] dapat menjadi indikasi untuk mendeteksi warna merah sebagai langkah praproses data citra mengingat pentingnya peranan warna kulit [16]. Langkah awal yang dilakukan pada proses ini adalah dengan menentukan rentang warna merah dalam format HSV lalu data citra dikonversi pada format HSV. Dari rentang warna yang sudah ditentukan kemudian dilakukan *masking* untuk mengekstrak warna merah pada data citra dengan fitur warna keluaran data citra adalah biner.

*d. Image Enhancement (Peningkatan Gambar) dan Red Color Detection*

Eksperimen selanjutnya adalah dengan mengombinasikan peningkatan kualitas citra dan juga deteksi warna merah pada wajah. Data citra ditingkatkan kualitasnya dengan menormalisasi gambar yang dimasukkan dengan mereduksi *noise* menggunakan filter bilateral yang kemudian dikonversi ke dalam fitur warna HSV. Dengan menetapkan rentang warna, proses dilanjutkan dengan melakukan *masking* untuk mengekstrak warna merah pada data citra dan kemudian diterapkan pada data asli sehingga keluaran data merupakan fitur warna HSV.

## Klasifikasi

Dalam memvalidasi praproses, selanjutnya dilakukan klasifikasi untuk memvalidasi tiap data masukan. Pada penelitian sebelumnya, metode klasifikasi yang digunakan adalah CNN [1][17][18][2] dimana model CNN dengan arsitektur VGG16 menghasilkan kinerja terbaik. Selain CNN dengan arsitektur VGG16, SVM merupakan salah satu metode klasifikasi yang digunakan pada penelitian sebelumnya dengan kinerja terbaik pada studi kasus yang berbeda [19]. Pemilihan metode klasifikasi KNN dikarenakan KNN merupakan algoritma yang didasarkan pada regresi dan klasifikasi dengan keunggulan dalam implementasi yang mudah dan pelatihan yang cepat [20] sedangkan NN sendiri dipilih



dikarenakan kemampuannya dalam komputasi secara paralel dan terdistribusi, pembelajaran fitur yang adaptif, toleransi kesalahan yang baik serta ketahanan yang kuat[21].

Sehingga metode klasifikasi yang diuji coba pada penelitian ini menggunakan SVM, KNN, NN dan VGG16. Adapun fitur ekstraksi yang digunakan pada percobaan ini adalah VGG16 yang kemudian dilanjutkan dengan penggunaan PCA (*principal component analysis*). Penggunaan PCA (*principal component analysis*) sebagai fitur ekstraksi juga menjadi salah satu bentuk percobaan dimana PCA merupakan teknik matematika yang mereduksi variabel menjadi kumpulan variabel yang lebih kecil [22]. PCA sendiri merupakan teknik standar sederhana dibandingkan dengan teknik lainnya [3] yang digunakan untuk mereduksi dimensi dan dapat diterapkan pada berbagai masalah [23].

## HASIL DAN PEMBAHASAN

Praproses data citra dilakukan dengan menggunakan beberapa metode dan dilakukan validasi yang disesuaikan dengan level keparahan jerawat. Adapun perbandingan data citra sebelum dan sesudah dilakukan praproses dapat dilihat pada gambar 3.



Gambar 3. Hasil Praproses Gambar Jerawat

Dapat dilihat pada Gambar 3 bahwasanya deteksi objek dalam hal ini jerawat memberikan hasil yang berbeda. Praproses dengan meningkatkan kualitas gambar menggunakan *enhanced image* memiliki kelebihan terhadap kontras warna sehingga area jerawat akan terlihat lebih menonjol meskipun pada gambar aslinya area-area tersebut terlihat agak samar. Penggunaan praproses *threshold* dengan menerapkan ambang batas yang sudah ditentukan menghasilkan citra biner dimana area gelap akan memberikan warna hitam, sayangnya objek jerawat yang harusnya memberikan warna hitam tidak seluruhnya terdeteksi. Berbeda dengan *red color detection* dimana praproses ini mendeteksi warna merah yang ada pada citra sehingga jerawat terdeteksi dengan baik, sama halnya dengan penggabungan *enhanced image* dan *red color detection*, dengan peningkatan kualitas gambar yang kemudian diekstrak warna kemerahannya menghasilkan data citra yang sensitif terhadap warna merah. Kesensitifan dari *red color detection* ataupun penggabungan *enhanced image* dan *red color detection* adalah semua objek yang termasuk dalam rentang warna merah yang telah ditentukan akan terdeteksi sehingga pada kasus ini area bibir atau area lain yang tampak kemerahan terdeteksi sebagai objek yang harus muncul.

Selanjutnya dilakukan proses klasifikasi sebagai bentuk validasi untuk mengetahui metode praproses data citra mana yang lebih baik. Penggunaan ekstraksi fitur VGG16 dipilih dikarenakan hasil uji coba ekstraksi fitur antara CNN dan VGG16 terhadap kumpulan data ACNE04 yang belum dilakukan praproses lebih baik seperti yang tersaji pada Tabel 1.

Tabel 1. Hasil Akurasi Ekstraksi Fitur

| Ekstraksi Fitur | Akurasi |
|-----------------|---------|
| CNN             | 46.72%  |
| VGG16           | 52.42%  |

Klasifikasi diuji coba dengan beberapa eksperimen dengan menggunakan 4 model klasifikasi yaitu NN, VGG16, SVM dan juga KNN. Atribut yang digunakan pada percobaan pertama yaitu dengan menggunakan masukan *shape* 32x32 piksel, *batch size* (32), dan jumlah epoch (50 & 80) dengan hasil percobaan seperti pada Tabel 2.

Tabel 2. Hasil Klasifikasi Percobaan Pertama

| Model Klasifikasi | Epoch | PCA | Hasil Akurasi   |           |              |                     |                               |
|-------------------|-------|-----|-----------------|-----------|--------------|---------------------|-------------------------------|
|                   |       |     | Tanpa Praproses | Threshold | Enhanced     | Red Color Detection | Enhanced+ Red Color Detection |
| VGG16             | 50    | -   | 52,42           | 49,29     | 55,67        | 49,29               | 48,29                         |
| NN                | 50    | v   | 42,88           | 41,71     | 45,33        | 40,74               | 43,71                         |
| VGG16             | 80    | -   | 53,28           | 48,29     | <b>59,33</b> | 47,86               | 50,00                         |
| NN                | 80    | v   | 41,60           | 41,31     | 44,67        | 41,03               | 40,29                         |
| SVM               | -     | v   | 45,29           | 44,72     | 46,43        | 43,87               | 41,14                         |
| KNN               | -     | v   | 41,31           | 38,86     | 49,67        | 40,46               | 38,57                         |


Dari hasil uji coba pertama, menggunakan metode VGG16 memberikan nilai yang terbaik, baik pada penggunaan epoch 50 atau 80 pada tiap praproses yang diujicobakan sebagai data masukan klasifikasi. Akurasi terbaik yang dihasilkan dari seluruh praproses yang diujicobakan adalah klasifikasi dengan penggunaan epoch 80 dengan data masukan yang digunakan adalah data yang telah ditingkatkan kualitas gambarnya dengan praproses *enhanced image* yang mencapai 59.33%, tentunya metode klasifikasi ini mengungguli metode klasifikasi lainnya seperti NN, SVM dan KNN yang secara berturut-turut menggunakan data masukan yang sama memberikan nilai akurasi 45.33% (epoch 50), 44.67% (epoch 80), 46.63% dan 49.67%. Pada uji coba pertama juga didapatkan fakta bahwasanya penggunaan PCA sebagai salah satu fitur ekstraksi tidak memberikan dampak dalam peningkatan akurasi.

Kemudian percobaan kedua dilakukan dengan menaikkan *input shape* menjadi 255x255 piksel dengan *batch size* tetap. Uji coba kedua fokus pada model yang memberikan akurasi tertinggi pada uji coba pertama yaitu VGG16 dengan jumlah epoch yang digunakan adalah 80 meskipun penggunaan epoch yang lebih besar belum tentu berbanding lurus dengan peningkatan akurasi. Dari uji coba kedua dengan meningkatkan data masukan citra tersebut menghasilkan akurasi yang lebih baik terlampir pada Tabel 3. Data masukan *enhanced image* memberikan akurasi terbaik dengan nilai akurasi mencapai 69%.

Tabel 3. Hasil Klasifikasi Percobaan Kedua

| Data                           | Akurasi      |
|--------------------------------|--------------|
| Threshold                      | 54,40        |
| Enhanced                       | <b>69,00</b> |
| Red Color Detection            | 52,99        |
| Enhanced + Red Color Detection | 54.86        |

Adapun beberapa tantangan dalam eksperimen ini salah satunya adalah warna kulit yang kontrasnya sangat rendah dikarenakan warna kulit pada kumpulan data ini cenderung kemerahan. Dengan menggunakan praproses *red color detection*, dengan ambang batas merah yang sudah ditentukan, warna kulit yang cenderung merah akan terdeteksi sebagai objek yang akan dipilih. Tantangan lainnya dengan menggunakan praproses *threshold*, objek jerawat dengan warna yang tidak pekat pada saat dikonversi menjadi gambar abu tidak akan terdeteksi sebagai objek. Pengambilan gambar yang tidak seragam dengan berbagai *noise* pada citra juga menjadi kendala dalam melakukan klasifikasi tingkat keparahan jerawat.



Gambar 4. Tantangan Praproses

## KESIMPULAN

Jerawat sebagai salah satu bagian dari dermatologi menjadi salah satu perhatian khusus. Tujuan utama dalam penelitian ini sendiri adalah diagnosis jerawat dimana terlebih dahulu dilakukan praproses data citra jerawat untuk selanjutnya dilakukan klasifikasi jerawat sesuai dengan tingkat keparahannya. Praproses data citra dilakukan dengan 4 percobaan yaitu *enhanced image*, *threshold*, *red color detection* dan penggabungan *enhanced image* dengan *red color detection*. Tingkat keparahan yang dibagi menjadi 4 kelas kemudian diuji coba dengan 4 jenis klasifikasi yaitu NN, VGG16, SVM dan KNN. Dari kelima data citra yang menjadi data masukan dilanjutkan dengan klasifikasi sebagai langkah validasi dari tiap praproses yang dilakukan didapatkan hasil akurasi tertinggi ada pada metode VGG16 dengan data masukan *enhanced imaged* dengan nilai tingkat akurasi 69%, namun hasil akurasi yang dihasilkan pada saat klasifikasi ini masih belum dapat mengungguli metode sebelumnya yang mencapai 84.52% [24]. Dari uji coba yang dilakukan didapatkan beberapa informasi bahwasanya untuk klasifikasi tingkat keparahan jerawat fitur ekstraksi PCA tidak meningkatkan hasil akurasi. Kemudian penggunaan *size* citra dan dengan data masukan praproses *enhanced* memberikan pengaruh yang signifikan terhadap hasil akurasi yang didapatkan karena peningkatan kualitas gambar yang dilakukan seperti normalisasi gambar, mengurangi *noise*, peningkatan kontras dan juga penajaman warna. Dapat disimpulkan bahwa praproses citra, ukuran data citra, fitur ekstraksi dan metode klasifikasi memberikan pengaruh terhadap nilai akurasi yang dihasilkan. Kedepannya penelitian ini dapat diuji coba dengan menggunakan kumpulan data dermatologi jerawat yang berbeda dikarenakan banyaknya *noise* pada kumpulan data ACNE04 yang juga menjadi kendala dalam praproses data citra sehingga berdampak pada hasil klasifikasi.

## REFERENSI

- [1] Y. Lin *et al.*, "KIEGLFN: A unified acne grading framework on face images," *Comput Methods Programs Biomed*, vol. 221, p. 106911, 2022, doi: 10.1016/j.cmpb.2022.106911.
- [2] R. Sadik, A. Majumder, A. A. Biswas, B. Ahammad, and M. M. Rahman, "An in-depth analysis of Convolutional Neural Network architectures with transfer learning for skin disease diagnosis," *Healthcare Analytics*, vol. 3, no. November 2022, p. 100143, 2023, doi: 10.1016/j.health.2023.100143.
- [3] E. Pintelas, I. E. Livieris, S. Kotsiantis, and P. Pintelas, "A multi-view-CNN framework for deep representation learning in image classification," *Computer Vision and Image Understanding*, vol. 232, no. January, p. 103687, 2023, doi: 10.1016/j.cviu.2023.103687.
- [4] E. Elyan *et al.*, "Computer vision and machine learning for medical image analysis: recent advances, challenges, and way forward," *Artificial Intelligence Surgery*, pp. 24–25, 2022, doi: 10.20517/ais.2021.15.
- [5] J. Gao, Y. Yang, P. Lin, and D. S. Park, "Editorial: Computer vision in healthcare applications," *J Healthc Eng*, vol. 2018, 2018, doi: 10.1155/2018/5157020.
- [6] F. D. Marleny, *Mengenal Pengolahan Citra Digital menggunakan Python*, no. January. 2021.
- [7] J. Zhang, Y. Xie, Q. Wu, and Y. Xia, "Medical image classification using synergic deep learning," *Med Image Anal*, vol. 54, pp. 10–19, 2019, doi: 10.1016/j.media.2019.02.010.
- [8] D. H. Xia *et al.*, "Review-material degradation assessed by digital image processing: Fundamentals, progresses, and challenges," *J Mater Sci Technol*, vol. 53, pp. 146–162, 2020, doi: 10.1016/j.jmst.2020.04.033.



- [9] S. Jardim, J. António, and C. Mora, "Image thresholding approaches for medical image segmentation-short literature review," *Procedia Comput Sci*, vol. 219, pp. 1485–1492, 2023, doi: 10.1016/j.procs.2023.01.439.
- [10] L. Qiao, K. Liu, Y. Xue, W. Tang, and T. Salehnia, "A multi-level thresholding image segmentation method using hybrid Arithmetic Optimization and Harris Hawks Optimizer algorithms," *Expert Syst Appl*, vol. 241, no. October 2023, p. 122316, 2023, doi: 10.1016/j.eswa.2023.122316.
- [11] J. Zheng, C. Tang, and Y. Sun, "Thresholding-accelerated convolutional neural network for aeroengine turbine blade segmentation," *Expert Syst Appl*, vol. 238, no. PF, p. 122387, 2024, doi: 10.1016/j.eswa.2023.122387.
- [12] S. Hao *et al.*, "Multi-threshold image segmentation using an enhanced fruit fly optimization for COVID-19 X-ray images," *Biomed Signal Process Control*, vol. 86, no. PA, p. 105147, 2023, doi: 10.1016/j.bspc.2023.105147.
- [13] S. Chen, Y. Li, Y. Zhang, Y. Yang, and X. Zhang, "Soft X-ray image recognition and classification of maize seed cracks based on image enhancement and optimized YOLOv8 model," *Comput Electron Agric*, vol. 216, no. December 2023, p. 108475, 2024, doi: 10.1016/j.compag.2023.108475.
- [14] K. A. Williams, B. Wondimu, A. M. Ajayi, and O. Sokumbi, "Skin of color in dermatopathology: does color matter?," *Hum Pathol*, vol. 140, pp. 240–266, 2023, doi: 10.1016/j.humpath.2023.04.012.
- [15] R. Ramli, A. S. Malik, A. F. M. Hani, and A. Jamil, "Acne analysis, grading and computational assessment methods: An overview," *Skin Research and Technology*, vol. 18, no. 1, pp. 1–14, 2012, doi: 10.1111/j.1600-0846.2011.00542.x.
- [16] B. Yuan, L. Han, and H. Yan, "Explore double-opponency and skin color for saliency detection," *Neurocomputing*, vol. 425, pp. 219–230, 2021, doi: 10.1016/j.neucom.2020.04.089.
- [17] Y. Lin *et al.*, "DED: Diagnostic Evidence Distillation for acne severity grading on face images," *Expert Syst Appl*, vol. 228, no. May, p. 120312, 2023, doi: 10.1016/j.eswa.2023.120312.
- [18] N. Aslan, G. Ozmen Koca, M. A. Kobat, and S. Dogan, "Multi-classification deep CNN model for diagnosing COVID-19 using iterative neighborhood component analysis and iterative ReliefF feature selection techniques with X-ray images," *Chemometrics and Intelligent Laboratory Systems*, vol. 224, no. November 2021, p. 104539, 2022, doi: 10.1016/j.chemolab.2022.104539.
- [19] M. Ahammed, M. Al Mamun, and M. S. Uddin, "A machine learning approach for skin disease detection and classification using image segmentation," *Healthcare Analytics*, vol. 2, no. April, p. 100122, 2022, doi: 10.1016/j.health.2022.100122.
- [20] Z. Fan, J. K. Xie, Z. Y. Wang, P. C. Liu, S. J. Qu, and L. Huo, "Image Classification Method Based on Improved KNN Algorithm," *J Phys Conf Ser*, vol. 1930, no. 1, 2021, doi: 10.1088/1742-6596/1930/1/012009.
- [21] P. Wang, E. Fan, and P. Wang, "Comparative analysis of image classification algorithms based on traditional machine learning and deep learning," *Pattern Recognit Lett*, vol. 141, pp. 61–67, 2021, doi: 10.1016/j.patrec.2020.07.042.
- [22] O. Attallah and D. A. Ragab, "Auto-MyIn: Automatic diagnosis of myocardial infarction via multiple GLCMs, CNNs, and SVMs," *Biomed Signal Process Control*, vol. 80, no. P1, p. 104273, 2023, doi: 10.1016/j.bspc.2022.104273.
- [23] S. S. Shirke, J. A. Kendule, and S. G. Vyawahare, "Techno-Societal 2016," *Techno-Societal 2016*, pp. 265–274, 2018, doi: 10.1007/978-3-319-53556-2.
- [24] Y. Lin, Y. Guan, Z. Ma, H. You, X. Cheng, and J. Jiang, "An Acne Grading Framework on Face Images via Skin Attention and SFNet," *Proceedings - 2021 IEEE International Conference on Bioinformatics and Biomedicine, BIBM 2021*, no. March, pp. 2407–2414, 2021, doi: 10.1109/BIBM52615.2021.9669431.